

Author: Liu Jian

Time: 2020-06-03

概要

机器学习1-线性回归

1 一元线性回归

2 多元线性回归

概要

应用:

1. 数据挖掘;
2. 计算机视觉;
3. 自然语言处理;
4. 机器决策 (无人驾驶等)。

解决的问题:

1. 回归问题;
2. 分类问题。

概念解释:

1. 归纳偏好, 可以理解为几个模型都可以时, 根据我们的偏好对此进行选择。比如, 奥卡姆剃刀会选择模型最“简单”的那一个。此外, 还有多释原则, (principle of multiple explanations), 即主张保留与经验观察一致的所有模型, 这与集成学习 (ensemble learning) 的理念相吻合。
2. No free lunch theorem (NFL) 告诉我们: 脱离具体问题, 空泛地谈论模型的好坏毫无意义, 因为若考虑所有潜在的问题 (针对所有问题求模型性能的期望), 则所有模型都一样好。我们可以这样理解, 对于模型 A , 若它在某些问题 (记问题的真实解为 S_1) 上比模型 B 好 (也就是 A 与 S_1 更贴近), 则必然存在另一些问题 (记问题的真实解为 S_2), 使得模型 B 比模型 A 好 (也就是 B 与 S_2 更贴近), 不存在一个模型能解决所有的问题 (即不存在一条具体的曲线对所有的解曲线都拟合得很好), 应该具体问题具体分析 (即对于具体问题求解相应的合适的拟合曲线)。

所谓“没有免费的午餐”, 如果不假定观察到的数据和未来的数据之间有一定的联系的话, 这个任务是无法完成的。而在统计学习中, 建立两者之间联系是通过一个共享的概率模型来实现的。--

pluskid

常用知识点

• 直线法向量与方向向量:

直线: $Ax + By + C = 0$ ($y = wx + b$)

点 $(x_1, y_1), (x_2, y_2)$ 在直线上, 相减得方向向量。

方向向量 $\langle x_1 - x_2, y_1 - y_2 \rangle \implies \langle B, -A \rangle$ 或 $\langle 1, w \rangle$ 。

法向量与方向向量垂直, 可得法向量 $\langle A, B \rangle$ 。

• 矩阵求微分常用公式:

$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}$$

$$\frac{\partial \mathbf{x}^T B \mathbf{x}}{\partial \mathbf{x}} = (B + B^T) \mathbf{x}$$

• 概率分布常用公式：

若有分布：

$$P(y) = \begin{cases} p, & y = 1 \\ 1 - p, & y = 0 \end{cases}$$

则概率分布可以写成如下等价的形式：

$$P(y) = p^y(1-p)^{(1-y)} \quad \text{或} \quad P(y) = yp + (1-y)(1-p)$$

在实际应用时，根据问题选用相应的形式。

• 二元函数凹凸性及最值定理：

- 凹凸性：设 $f(x, y)$ 在区域 \mathcal{D} 上具有二阶连续偏导数，记 $A = f''_{xx}(x, y), B = f''_{xy}(x, y), C = f''_{yy}(x, y)$ 则：
 - (1) 在 \mathcal{D} 上恒有 $A > 0$ ，且 $AC - B^2 \geq 0$ 时， $f(x, y)$ 在区域 \mathcal{D} 上是凸函数；
 - (2) 在 \mathcal{D} 上恒有 $A < 0$ ，且 $AC - B^2 \geq 0$ 时， $f(x, y)$ 在区域 \mathcal{D} 上是凹函数；
- 最值：设 $f(x, y)$ 是在开区域 \mathcal{D} 内具有连续偏导数的凸(或者凹)函数， $(x_0, y_0) \in \mathcal{D}$ 且 $f'_x(x_0, y_0) = 0, f'_y(x_0, y_0) = 0$ ，则 $f(x_0, y_0)$ 为 $f(x, y)$ 在 \mathcal{D} 内的最小值(或最大值)。

• 多元实值函数凹凸性及最值：

- 多元实值函数凹凸性判定定理：设 $\mathcal{D} \in R^n$ 是非空开凸集， $f: \mathcal{D} \subset R^n \rightarrow R$ ，且 $f(x)$ 在 \mathcal{D} 上二阶连续可微，如果 $f(x)$ 的 Hessian 矩阵 $\nabla^2 f(x)$ 在 \mathcal{D} 上是正定的，则 $f(x)$ 是 \mathcal{D} 上的严格凸函数。
- 凸充分性定理：若 $f: R^n \rightarrow R$ 是凸函数，且 $f(x)$ 一阶连续可微，则 x^* 是最小值的充要条件为 $\nabla f(x^*) = 0$ 。

机器学习1-线性回归

内容：一元线性回归；多元线性回归；广义线性模型；对数几率回归（逻辑斯谛回归）

1 一元线性回归

模型： $f(x) = wx + b$, s.t. $f(x_i) \simeq y_i$

参数估计方法：最小化平方损失函数/最小二乘法

参数计算公式：

$$w = \frac{\mathbf{x}_d^T \mathbf{y}_d}{\mathbf{x}_d^T \mathbf{x}_d} b = \bar{y} - w\bar{x}$$

其中， $\mathbf{x}_d = \langle x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_m - \bar{x} \rangle^T$ ， $\mathbf{y}_d = \langle y_1 - \bar{y}, y_2 - \bar{y}, \dots, y_m - \bar{y} \rangle^T$ 。平均值 $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$ ， $\bar{y} = \frac{1}{m} \sum_{i=1}^m y_i$ 。

2 多元线性回归

模型： $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$, s.t. $f(\mathbf{x}_i) \simeq y_i$

参数估计方法：最小化平方损失函数/最小二乘法

参数计算公式：见西瓜书P55
